

MOPPO: Aprendizaje por Refuerzo Multi-Objetivo con Curriculum Learning para Anonimización de Grafos

Abril Minerva Estrada Montano Sebastian Alanis González

Licenciatura en Ciencia de Datos

Materia: Aprendizaje por Refuerzo

Profesora: Ileana Angélica Grave Aguilar

Repositorio: <https://github.com/xaprilapril/RL-MOPPO>

abrilminerva@gmail.com sebastian.alanis@gmail.com

Resumen—Este trabajo presenta MOPPO, un enfoque de aprendizaje por refuerzo multi-objetivo para anonimización de grafos. El problema se plantea como una negociación entre privacidad y utilidad estructural: al modificar una red para proteger la identidad de sus nodos, también se altera la topología que permite analizar comunidades, triángulos, hubs y patrones de conectividad. Para estudiar esta tensión, formulamos la anonimización por grado como un MDP multi-objetivo y comparamos una política PPO condicionada por pesos contra baselines fijos, heurísticos y aleatorios. El reporte integra el paper base, los resultados del repositorio RL-MOPPO y el notebook *Baseline Comparison RL-MOPPO*. A diferencia de una versión corta de artículo, aquí conservamos una explicación amplia de las figuras, de las métricas y de las limitaciones, porque la lectura del proyecto depende de entender no solo qué método gana una métrica, sino qué tipo de intervención produce sobre el grafo.

Palabras clave—Anonimización de grafos, aprendizaje por refuerzo multi-objetivo, PPO, curriculum learning, action masking, k-anonimato, frentes de Pareto, hipervolumen, baselines greedy, equidad algorítmica.

I. RESUMEN EXTENDIDO Y LECTURA GENERAL

Este reporte presenta una versión ampliada y más explicativa de nuestro proyecto MOPPO, un enfoque de aprendizaje por refuerzo multi-objetivo para anonimización de grafos. El problema parte de una tensión muy concreta: al modificar una red social para proteger la identidad de sus nodos, también se altera la topología que permite analizarla. Por ello no basta con maximizar privacidad de manera aislada;

hace falta estudiar el compromiso entre privacidad, utilidad, costo estructural y estabilidad del método.

Retomamos el paper base del proyecto, donde se formula la anonimización por grado como un MDP multi-objetivo con una política PPO condicionada por pesos, action masking basado en déficit de k -anonimato y curriculum learning en tres fases. En esa primera versión se reportaron experimentos sobre Karate Club y un subgrafo de Facebook, junto con análisis de frentes de Pareto, hipervolumen, equidad por cuartiles y TREX. En esta versión extendida agregamos una comparación de baselines ejecutada en el notebook *Baseline Comparison RL-MOPPO: Fixed-alpha PPO, Random Masked, Greedy Liu-Terzi style y Alpha-Greedy Rollout*. Esta última línea base se incorporó porque evalúa cada acción usando el mismo valor de α con el que se mide el episodio, lo que la vuelve una referencia más justa para discutir comportamiento multi-objetivo.

La lectura final no se reduce a declarar un ganador único. Random Masked obtiene el mayor hipervolumen en la corrida del notebook, pero lo hace a costa de modificar muchas aristas y deteriorar utilidad. Alpha-Greedy Rollout obtiene el mejor score ponderado promedio, lo que sugiere una buena lectura local del trade-off. MOPPO, por su parte, aparece como el método más conservador estructuralmente y el que mejor preserva clustering, aunque en una corrida corta no siempre domina en hipervolumen. Nuestra interpretación es que el proyecto evidencia

algo importante para aprendizaje por refuerzo: una política aprendida no debe juzgarse únicamente por una métrica agregada, sino por su capacidad de adaptarse a preferencias, conservar estructura y sostener una familia coherente de soluciones.

Palabras clave: Anonimización de grafos; aprendizaje por refuerzo multi-objetivo; PPO; curriculum learning; action masking; k -anonimato; frentes de Pareto; hipervolumen; baselines greedy; equidad algorítmica.

Cómo debe leerse este reporte: El documento conserva una extensión de reporte porque el proyecto no se entiende bien si se reduce a una tabla final. Las gráficas no se agregaron como decoración: cada una responde una pregunta distinta sobre el comportamiento de los métodos. En ese sentido, intentamos escribir el reporte como lo explicaríamos frente al equipo y frente a la profesora: con rigor en la formulación, pero también con una lectura clara de qué significa cada resultado para la anonimización de una red social.

II. INTRODUCCIÓN

La privacidad en redes sociales suele contarse como una historia de eliminación: quitar nombres, quitar identificadores, quitar atributos. Sin embargo, en grafos el problema es más delicado. Aunque eliminemos los nombres de las personas, la estructura de conexiones puede seguir siendo altamente identificable. Un nodo con un grado raro, una combinación de vecinos particular o una posición muy específica dentro de la red puede funcionar casi como una huella digital. Por eso, la anonimización de grafos no se limita a borrar etiquetas: requiere modificar la estructura misma.

Esa modificación abre el dilema central del proyecto. Si alteramos demasiadas aristas, podemos mejorar la privacidad, pero el grafo deja de representar el fenómeno original. Si alteramos muy pocas, conservamos utilidad, pero quizás dejamos nodos identificables. Nuestro trabajo se ubica exactamente en esa frontera: no buscamos una única respuesta absoluta, sino una forma de recorrer el espectro entre privacidad y utilidad.

Los métodos clásicos, como el esquema de anonimización por secuencia de grados de [6], proponen transformar el grafo para que cada nodo comparta su

grado con al menos otros $k - 1$ nodos. Esto introduce una noción clara de privacidad: si varios nodos son indistinguibles por grado, un atacante que use esa señal tendrá más dificultad para reidentificarlos. El problema es que estos métodos suelen operar con una función de costo fija. En otras palabras, resuelven una versión del problema, pero no preguntan qué preferencia particular tiene el usuario entre privacidad y utilidad.

Nosotros partimos de una idea distinta: esa preferencia depende del contexto. En un caso sensible, como una red de pacientes, puede ser razonable sacrificar más estructura para proteger identidad. En una red de recomendaciones o colaboración científica, perder clustering o comunidades puede hacer que el grafo deje de ser útil. Por eso formulamos la anonimización como un problema de aprendizaje por refuerzo multi-objetivo (MORL), donde el agente no aprende una sola política rígida, sino una política condicionada por el peso α . Ese peso indica cuánta importancia damos a privacidad frente a utilidad.

Contribución e interpretación central: La contribución del proyecto no es decir “este método siempre gana”, sino construir una forma de observar el problema. MOPPO permite estudiar cómo cambia la política cuando cambia la preferencia; los baselines permiten saber cuándo una heurística simple basta; y las gráficas permiten ver si el método protege, conserva o destruye estructura.

III. TRABAJO RELACIONADO Y LUGAR DEL PROYECTO

III-A. Anonimización de grafos

La anonimización por grado parte de una intuición directa: si el grado de un nodo es único, ese nodo puede ser vulnerable. En el esquema de [6], el objetivo es modificar la secuencia de grados para que cada grado aparezca al menos k veces. Esto genera clases de equivalencia y reduce la posibilidad de reidentificar nodos usando únicamente el grado. Trabajos posteriores, como [11], extienden el análisis a ataques basados en vecindarios. La dificultad es que modificar un grafo para cumplir privacidad con cambios mínimos es un problema combinatorio complejo; de hecho, [2] muestran la dificultad computacional de variantes generales del problema.

Este proyecto se apoya en esa línea, pero cambia la pregunta. En lugar de buscar únicamente la solución de menor costo para alcanzar k -anonimato, preguntamos: ¿qué pasa si queremos distintos niveles de privacidad? ¿Qué pasa si en algunos casos preferimos preservar clustering? ¿Qué pasa si queremos observar toda la frontera de soluciones posibles?

III-B. Aprendizaje por refuerzo en grafos

El aprendizaje por refuerzo es natural cuando una solución se construye paso a paso. En nuestro caso, cada paso corresponde a decidir si se agrega o elimina una arista. Esa decisión modifica el estado del grafo y cambia las recompensas futuras. La literatura ha usado RL en tareas sobre grafos, por ejemplo para generación molecular o diseño de estructuras [9, 12]. En anonimización, [3] proponen usar DQN con recompensa de privacidad. Nuestra diferencia es que la privacidad no se trata como único objetivo; se combina con una señal de utilidad estructural.

III-C. MORL y políticas condicionadas por pesos

El aprendizaje por refuerzo multi-objetivo reconoce que muchos problemas reales no tienen una sola recompensa. En lugar de optimizar una métrica, se trabaja con varias señales potencialmente contradictorias. Una estrategia común es escalarizar recompensas con un peso α ; otra, más flexible, consiste en condicionar la política por ese peso. En esa línea, [1] y [8] discuten adaptación de políticas en MORL; [4] aplica ideas relacionadas a PPO. MOPPO adopta esta filosofía: el agente observa el grafo y también observa la preferencia $[\alpha, 1 - \alpha]$.

IV. FORMULACIÓN MATEMÁTICA DEL PROBLEMA

Sea $G_0 = (V, E_0)$ el grafo original. El objetivo es producir un grafo modificado $G = (V, E)$ que mejore privacidad sin alejarse demasiado de la estructura inicial. En el proyecto trabajamos con privacidad por k -anonimato de grado. Un grafo es k -anónimo por grado si para todo nodo v existen al menos $k - 1$ nodos adicionales con el mismo grado:

$$\forall v \in V : |\{u \in V : \deg_G(u) = \deg_G(v)\}| \geq k. \quad (1)$$

A partir de esta definición, medimos el déficit de anonimato como la cantidad de nodos que pertenecen a clases de grado demasiado pequeñas. La recompensa de privacidad se escribe como:

$$r_{\text{priv}}(G) = -\frac{1}{|V|} \sum_{v \in V} \max\{0, k - |\text{clase}(v)|\}. \quad (2)$$

El signo negativo es importante. La recompensa se acerca a cero cuando el grafo cumple mejor el criterio de anonimato. Es decir, valores menos negativos son mejores.

La utilidad se mide con dos ideas complementarias. Durante el entrenamiento se usa una señal proxy basada en el costo de modificar aristas:

$$r_{\text{util}}^{\text{proxy}}(G) = -\frac{|E \triangle E_0|}{|E_0|}, \quad (3)$$

donde $E \triangle E_0$ representa el conjunto de aristas que cambiaron respecto al grafo original. Para evaluación también se considera la preservación del coeficiente de clustering promedio:

$$r_{\text{util}}^{\text{real}}(G) = -|C(G) - C(G_0)|. \quad (4)$$

La recompensa escalar que permite comparar acciones bajo una preferencia determinada es:

$$r(G; \alpha) = \alpha r_{\text{priv}}(G) + (1 - \alpha) r_{\text{util}}(G), \quad \alpha \in [0, 1]. \quad (5)$$

Cuando α se acerca a 1, el agente prioriza privacidad. Cuando α se acerca a 0, el agente prioriza utilidad. Esta variable es el puente entre el enfoque clásico y el enfoque multi-objetivo: en lugar de entrenar un modelo nuevo para cada preferencia, buscamos que una sola política aprenda a comportarse de manera distinta según α .

V. EL MDP DE ANONIMIZACIÓN

V-A. Estado

El estado usado por el agente resume información estructural del grafo y de la preferencia actual. En el notebook *Baseline Comparison RL-MOPPO* se replica la idea del repositorio: la observación incluye grados normalizados, déficit de anonimato por nodo y

el vector de preferencia $[\alpha, 1 - \alpha]$. Esta construcción es compacta, pero contiene las señales necesarias para decidir qué nodos están en riesgo y qué objetivo se está priorizando.

V-B. Acciones

El espacio de acciones contiene todas las posibles operaciones *flip* sobre pares de nodos, más una acción *no-op*. Una acción *flip* agrega una arista si no existe o la elimina si ya existe. Para un grafo con n nodos, esto produce:

$$|\mathcal{A}| = \binom{n}{2} + 1. \quad (6)$$

Este crecimiento cuadrático explica por qué el problema se vuelve difícil rápidamente. Para Karate Club, con 34 nodos, hay 562 acciones. Para un subgrafo de Facebook con 100 nodos, hay 4,951 acciones. En grafos más grandes, el vector de logits del actor puede convertirse en el cuello de botella principal.

V-C. Transición

La transición es determinista respecto a la acción: si el agente elige una arista, el ambiente cambia su presencia; si elige *no-op*, el grafo permanece igual. Lo que vuelve difícil el problema no es el azar de la transición, sino el efecto combinatorio de cada modificación. Una arista puede cambiar el grado de dos nodos, alterar clases de equivalencia, modificar triángulos y mover el punto final en el plano privacidad-utilidad.

V-D. Recompensa

La recompensa combina privacidad y utilidad. Esta combinación no pretende ocultar que hay dos objetivos; al contrario, permite estudiar cómo cambia la decisión al variar α . Por eso no reportamos solamente recompensa promedio, sino también hipervolumen, frentes de Pareto, score por α , costo de aristas y preservación de clustering.

VI. MOPPO: ARQUITECTURA, ACTION MASKING Y CURRICULUM

VI-A. Arquitectura actor-crítico

MOPPO usa una red actor-crítico. El actor produce una distribución sobre acciones; el crítico estima el valor esperado del estado. La entrada incluye la observación del grafo y el peso α , por lo que la política puede condicionar sus decisiones a la preferencia actual. En términos prácticos, esto significa que el mismo modelo puede actuar de forma más conservadora cuando α es bajo y más agresiva cuando α es alto.

VI-B. Action masking

Una de las aportaciones técnicas del proyecto original es el uso de *action masking*. En lugar de permitir que el agente elija cualquier arista, el ambiente identifica nodos en riesgo:

$$\mathcal{R}_t = \{v : |\text{clase}(v)| < k\}. \quad (7)$$

Luego permite únicamente acciones incidentes en esos nodos, además de *no-op*. La máscara no cambia el espacio teórico de acciones, pero reduce el espacio efectivo. Esto ayuda al entrenamiento porque evita que PPO desperdicie probabilidad en acciones que difícilmente corrigen el déficit de anonimato.

Por qué la máscara importa en PPO: En PPO se calcula un cociente entre la probabilidad de la acción bajo la política nueva y la probabilidad bajo la política anterior. Si una acción era inválida durante el rollout pero después se evalúa como si fuera válida, el cociente de probabilidades deja de representar el mismo problema. Por eso la máscara debe guardarse y reaplicarse durante la actualización. Este detalle parece técnico, pero es central para evitar inestabilidad.

VI-C. Curriculum learning

El entrenamiento multi-objetivo puede ser inestable porque al inicio el agente no sabe ni anonimizar ni preservar utilidad. Si se le presentan todos los valores de α desde el primer momento, recibe señales contradictorias. El curriculum del paper separa el aprendizaje en tres fases: primero privacidad, luego utilidad, después mezcla. La idea es pedagógica

Cuadro I: Fases del curriculum usadas en el proyecto original.

Fase	Objetivo didáctico	Distribución de α
1	Aprender a corregir anonimato	$U(0.95, 1.00)$
2	Aprender a conservar estructura	$U(0.00, 0.05)$
3	Interpolar preferencias	$U(0, 1)$




Figura 1: Curvas de convergencia suavizadas (ventana 10 iters)

Figura 1: Figura original del paper: curvas de convergencia suavizadas y comparación de hipervolumen final por configuración. Esta figura muestra que el curriculum permite que la recompensa mejore por fases, especialmente en la etapa enfocada en privacidad.

incluso para el agente: antes de pedirle que negocie, se le enseña qué significa cada extremo.

off se vuelve más duro; Facebook agrega escala y heterogeneidad.

VII. EXPERIMENTOS DEL PAPER BASE

El paper original evaluó MOPPO en tres configuraciones: Karate Club con $k = 2$, Karate Club con $k = 4$ y un subgrafo de Facebook con 100 nodos. La evaluación principal usa 21 valores de α y varios episodios por preferencia. También se reportan frentes de Pareto, hipervolumen, análisis TREX y auditoría de equidad.

VII-A. Curvas de entrenamiento e hipervolumen original

La Figura 1 resume dos fenómenos. El primero es dinámico: la recompensa no mejora de forma lineal, sino por etapas. Esto es esperable porque el curriculum cambia la distribución de preferencias. El segundo fenómeno es comparativo: el hipervolumen final depende de la dificultad del grafo. Karate con $k = 2$ resulta más sencillo; Karate con $k = 4$ exige clases de grado más grandes y por eso el trade-

VII-B. Frentes de Pareto originales

Los frentes de Pareto del paper permiten leer el proyecto como una familia de decisiones, no como una sola salida. En Karate $k = 2$, el frente se concentra porque el problema es relativamente fácil: varios pesos llegan a soluciones muy parecidas. En Karate $k = 4$, el frente se abre y aparece un conflicto más visible. En Facebook, el frente es más rico: la heterogeneidad del grafo ofrece más combinaciones entre privacidad y utilidad.

VII-C. Comparación original con PPO de alpha fijo

La comparación original tenía un propósito distinto al notebook de comparación. Ahí se comparaba MOPPO contra modelos PPO entrenados con preferencias fijas: $\alpha = 0$, $\alpha = 0.5$ y $\alpha = 1$. Esta comparación es importante porque muestra el costo de tener políticas especializadas. Una política de utilidad puede conservar bien el grafo, pero no




Figura 2: Frentes de Pareto del paper base para Karate $k = 2$, Karate $k = 4$ y Facebook $n = 100$. El color representa el peso de privacidad α ; las estrellas señalan puntos no dominados.

(a) Karate $k = 2$. HV = 0,973, 1 pto. (b) Karate $k = 4$. HV = 0,388, 3 ptos. ptos.

Figura 2: Frentes de Pareto de MOPPO. Color del punto: α (azul/morado = utilidad, amarillo/verde = privacidad). Estrellas rojas señalan puntos no dominados.

Tabla 2: Comparación de HV, puntos Pareto y Δ entre MOPPO y baselines PPO de α fijo. Todos se evalúan con 21 valores de α en 5 episodios. **Negrita:** mejor HV. Subrayado: menor Δ (mas equitativo).

Metodo	Karate $k = 2$	Karate $k = 4$	Facebook $n = 100$
--------	----------------	----------------	--------------------

Figura 3: Tabla original del paper: comparación de hipervolumen, puntos Pareto e índice de disparidad entre MOPPO y baselines PPO de α fijo.

PPO $\alpha = 0,0$ (utilidad)	0.9583	1
PPO $\alpha = 0,5$ (fijo)	0.9630	1
PPO $\alpha = 1,0$ (privacidad)	0.9714	1
MOPPO (ours)	0.9727	1




Figura 4: Análisis TREX del paper base. Se agrupan trayectorias según perfiles acumulados de recompensa para observar si el comportamiento aprendido se separa de acuerdo con preferencias.

necesariamente anonimiza; una política de privacidad puede mejorar anonimato, pero perder estructura; una política fija intermedia puede funcionar en su zona, pero no cubre todas las preferencias.

VII-D. TREX y equidad en el paper base

TREX ayuda a mirar el aprendizaje como comportamiento, no solamente como punto final. Si las trayectorias se agrupan de forma coherente con α ,

entonces hay evidencia de que el condicionamiento por pesos está funcionando. Esto no significa que el agente sea perfecto; significa que el modelo no ignora la preferencia.

La auditoría de equidad abre una lectura más social del problema. No todas las aristas tienen el mismo significado estructural. Modificar una arista de un nodo periférico puede cambiar de forma fuerte su posición relativa, mientras que un hub

Figura 3: Analisis TREX: scatter por cluster, distribución α por cluster e índice Δ por cluster. Línea naranja: umbra 1,5.



Figura 5: Auditoría de equidad del paper base. El índice Δ compara impacto relativo en nodos periféricos frente a hubs.




Figura 6: Figura original del paper: comparación de hipervolumen y cobertura del frente de Pareto entre MOPPO y baselines PPO de α fijo.

absorbe mejor perturbaciones. Por eso el paper reporta que los nodos periféricos suelen pagar más costo relativo. Este hallazgo es relevante porque revela que anonimizar no solo implica cuánto se modifica el grafo, sino a quién afecta la modificación.

La Figura 6 muestra por qué el hipervolumen debe leerse junto con cobertura del frente. Un método puede ganar hipervolumen por algunos puntos fuertes, pero una política multi-objetivo debería evaluarse también por su capacidad de ofrecer alternativas. En el paper base, MOPPO destaca por producir más puntos Pareto en varios escenarios, especialmente en Facebook.

VIII. NOTEBOOK *Baseline Comparison RL-MOPPO*: COMPARACIÓN AMPLIADA DE BASELINES

A partir de la retroalimentación recibida, fortalecimos la parte experimental del proyecto. El paper original planteaba con claridad la formulación del método, el uso de PPO condicionado por pesos, el action masking y la auditoría de equidad; sin em-

bargo, la comparación necesitaba dialogar con más referencias, más semillas y más visualizaciones. Por ello construimos el notebook *Baseline Comparison RL-MOPPO*, cuyo propósito es reunir en un mismo flujo analítico el ambiente, las recompensas, MOPPO, los baselines y la lectura gráfica de resultados. Esta segunda etapa no sustituye al paper base: lo acompaña y lo vuelve más defendible, porque permite contrastar la política aprendida contra heurísticas y políticas fijas bajo las mismas métricas.

VIII-A. Configuración experimental del notebook

En la corrida que analizamos, el grafo base fue Karate Club con 34 nodos y 78 aristas. El ambiente tiene 562 acciones: una por cada posible par de nodos más la acción *no-op*. La privacidad inicial fue $r_{\text{priv}} = -0.1765$, lo que significa que al inicio existen clases de grado con menos de k nodos. También se identificaron seis clases deficientes de grado. Estos datos son importantes porque establecen la dificultad inicial del problema: el grafo no parte anonimizado, pero tampoco es un caso extremo.

Cuadro II: Diagnóstico del grafo original usado en el notebook *Baseline Comparison RL-MOPPO*.

Métrica	Valor
Nodos	34
Aristas	78
Densidad	0.1390
Grado promedio	4.5882
Desviación estándar del grado	3.8204
Grado mínimo / máximo	1 / 17
Clustering promedio	0.5706
Transitividad	0.2557
Componentes conexas	1
r_{priv} inicial	-0.1765
Clases de grado deficientes	6

El notebook utiliza semillas 0 y 1, cinco valores de α (0, 0.25, 0.5, 0.75, 1) y una configuración ligera para que el experimento sea reproducible en una sesión estándar de trabajo. Esta decisión es importante: no intenta reemplazar una corrida larga de publicación, sino producir una comparación reproducible y pedagógica que permita observar tendencias.

VIII-B. Familias de métodos comparados

MOPPO: MOPPO representa la hipótesis principal del proyecto: una sola política condicionada por α debería poder adaptarse a distintas preferencias. En la corrida del notebook, al ser corta, no esperamos necesariamente que domine todas las métricas; sí esperamos que muestre comportamiento conservador y coherente con la formulación multi-objetivo.

Fixed-alpha PPO: Este baseline entrena o evalúa una política con una preferencia fija. Funciona como referencia para saber qué se gana y qué se pierde cuando no se condiciona la política por pesos variables. Su limitación conceptual es clara: una política fija no está diseñada para cubrir todo el frente de Pareto.

Random Masked: Random Masked elige acciones válidas bajo la máscara, pero sin razonar explícitamente sobre privacidad o utilidad. Es una línea base inferior en sentido algorítmico: si obtiene buenos valores en alguna métrica agregada, eso debe interpretarse con cautela, porque puede deberse a exploración agresiva o a modificaciones excesivas.

Greedy Liu-Terzi style: Este baseline representa una heurística clásica: intenta mejorar privacidad de forma local, inspirada en la idea de agrupar grados

para reducir déficit de anonimato. Es fuerte cuando el objetivo principal es corregir clases de grado, pero no necesariamente responde bien a distintas preferencias α .

Alpha-Greedy Rollout: Este es el baseline nuevo. Evalúa acciones candidatas usando el mismo score escalarizado con el que se mide el episodio: $\alpha r_{\text{priv}} + (1 - \alpha) r_{\text{util}}$. Por eso es un baseline más justo para una comparación multi-objetivo: no optimiza solo privacidad ni solo utilidad, sino el compromiso específico de cada α .

IX. RESULTADOS GLOBALES DEL NOTEBOOK

Antes de discutir cada figura, conviene aclarar cómo leemos las métricas. En este proyecto los valores de recompensa son negativos porque miden déficit o pérdida: por tanto, acercarse a cero significa mejorar. Esta convención puede parecer poco intuitiva al principio, pero permite expresar privacidad y utilidad como costos que se reducen. Por esa razón, a lo largo del reporte evitamos declarar conclusiones a partir de una sola columna; cada resultado se interpreta junto con el costo estructural y con la forma del frente de Pareto.

La Tabla III es el punto de partida de la discusión. A primera vista, Random Masked obtiene el mayor hipervolumen. Sin embargo, esta victoria no puede leerse como superioridad metodológica completa, porque también presenta el mayor cambio promedio de aristas y el peor r_{util} promedio. En otras palabras, cubre espacio en el plano privacidad-utilidad, pero lo hace perturbando mucho el grafo.

Greedy Liu-Terzi style obtiene la mejor privacidad promedio. Esto tiene sentido: su regla local está

Cuadro III: Resumen global por método en la corrida del notebook. Valores menos negativos son mejores para r_{priv} , r_{util} y score.

Método	r_{priv}	r_{util}	Score	Cambio aristas	HV	Pareto
Random Masked	-0.0294	-0.1076	-0.0713	0.1955	0.9845	1
Greedy Liu-Terzi style	-0.0250	-0.0445	-0.0369	0.0288	0.9697	2
MOPPO	-0.1176	-0.0035	-0.0602	0.0128	0.8819	1
Alpha-Greedy Rollout	-0.0574	-0.0257	-0.0225	0.0212	0.8235	3
Fixed-alpha PPO	-0.1471	-0.0206	-0.0841	0.0179	0.7913	4

diseñada para reducir déficit de anonimato. Alpha-Greedy Rollout obtiene el mejor score ponderado promedio, lo que sugiere que, cuando se evalúa con el mismo α que guía la decisión, una heurística local bien alineada puede ser muy competitiva. MOPPO aparece como el método más conservador: modifica menos aristas y preserva mejor el clustering, aunque en esta corrida corta no logra el mejor score ni el mayor hipervolumen.

Síntesis interpretativa de resultados: El mayor hipervolumen lo obtuvo Random Masked (HV = 0.9845), lo que sugiere un frente amplio respecto al punto de referencia considerado. Sin embargo, este resultado debe leerse junto con su costo estructural: también fue el método que más aristas modificó. El mejor score ponderado promedio lo obtuvo Alpha-Greedy Rollout ($\text{score} = -0.0225$), lo cual indica que la heurística nueva responde bien al valor de α usado en evaluación. El método más conservador estructuralmente fue MOPPO, con un cambio promedio de aristas de 0.0128; esto sugiere que la política aprendida, al menos en esta corrida ligera, prefiere preservar estructura antes que realizar perturbaciones agresivas.

X. ANÁLISIS VISUAL E INTERPRETACIÓN DE RESULTADOS

X-A. Grafo original

La Figura 7 nos recuerda que no estamos trabajando con una tabla independiente de observaciones, sino con una estructura relacional. Cada nodo obtiene significado por sus conexiones. En anonimización de grafos, modificar una arista no es equivalente a alterar una celda aislada: cambia el grado de dos nodos, puede crear o destruir triángulos y puede afectar la posición relativa de nodos periféricos. Por eso, antes de hablar de métricas, conviene mirar el objeto que estamos modificando. En nuestro caso, esta

visualización funciona como un punto de partida: nos permite recordar que cada decisión del agente tiene una consecuencia visible sobre la red, no solamente sobre una columna de resultados. Esa lectura es importante porque hace más natural la interpretación posterior de costo estructural, clustering y privacidad.

X-B. Distribución de grados original

La Figura 8 explica por qué el k -anonimato por grado es una restricción no trivial. Los grados no aparecen todos con la misma frecuencia; algunos valores son raros. Esos grados raros crean clases pequeñas y, por lo tanto, nodos vulnerables bajo un atacante que use la secuencia de grados. La anonimización busca aumentar el tamaño de esas clases, pero hacerlo puede requerir agregar o quitar aristas. Aquí nace el conflicto: corregir grados puede dañar clustering. Dicho de forma más intuitiva, para que varios nodos terminen compartiendo grado, el algoritmo debe mover aristas; pero esas aristas no son intercambiables, porque algunas sostienen triángulos o conectan zonas importantes del grafo. Por eso la distribución de grados no solo diagnostica privacidad inicial, también anticipa el tipo de daño estructural que podría aparecer durante la anonimización.

X-C. Comparación privacidad-utilidad por método

La Figura 9 coloca cada método en el plano donde vive el problema. El eje de privacidad y el eje de utilidad se interpretan con valores negativos: acercarse a cero es mejor. Un método ideal estaría cerca del origen, pero el origen completo no siempre es alcanzable porque mejorar privacidad suele exigir cambios estructurales.

Random Masked aparece con buena privacidad, pero mala utilidad: explora y modifica lo suficiente como para reducir déficit, pero no controla el daño estructural. Greedy Liu-Terzi style mejora privacidad

Grafo original: tamaño de nodo proporcional al grado




Figura 7: Visualización del grafo Karate Club original.




Figura 8: Distribución de grados del grafo original.




Figura 9: Comparación global de privacidad y utilidad por método.

de forma más dirigida. MOPPO se mantiene cerca de buena utilidad, reflejando que cambia poco el grafo. Alpha-Greedy Rollout se ubica como una solución intermedia más balanceada, lo que coincide con su score promedio. Esta figura, por tanto, resume la tensión del proyecto: no basta con decir que un método se acerca más al origen; necesitamos entender qué camino tomó para llegar ahí, cuántas aristas modificó y si ese comportamiento se mantiene cuando cambia la preferencia.

X-D. Score promedio por preferencia α

La Figura 10 es una de las más importantes para conectar el notebook con MORL. El score no se calcula igual para todos los valores de α : cuando $\alpha = 0$, prácticamente solo importa utilidad; cuando $\alpha = 1$, solo importa privacidad. Por eso, una curva buena no es simplemente la que está arriba en un punto, sino la que responde de forma razonable a todo el rango de preferencias.

Alpha-Greedy Rollout destaca porque su regla de decisión usa exactamente el mismo α de evaluación.

Esto le permite adaptarse localmente al criterio. MOPPO, en cambio, depende de lo que haya aprendido durante entrenamiento; si la corrida es corta, puede actuar de forma conservadora y no explotar completamente las regiones de privacidad alta. Esta diferencia no invalida MOPPO: muestra que una heurística local puede ser fuerte en problemas pequeños, mientras que el aprendizaje necesita entrenamiento suficiente para superar reglas codificadas. En una lectura más honesta, esta gráfica nos ayuda a reconocer que el aprendizaje por refuerzo no debe defenderse por inercia: se justifica cuando aporta adaptabilidad, generalización o comportamiento consistente en escenarios donde las reglas locales dejan de ser suficientes.

X-E. Hipervolumen por método

El hipervolumen resume cuánto espacio domina el conjunto de soluciones de un método respecto a un punto de referencia. Es una métrica útil porque no mira solo privacidad ni solo utilidad. Sin embargo, también puede ser engañosa si se interpreta sola. En




Figura 10: Score promedio por valor de α .




Figura 11: Hipervolumen por método en la corrida del notebook.

la Figura 11, Random Masked gana hipervolumen. La razón probable es que, al alterar muchas aristas, alcanza un punto con privacidad fuerte que domina gran área del plano. Pero esa área se obtiene con costo estructural alto.

Por eso, nuestra lectura es cuidadosa: Random Masked no se vuelve el método recomendado por ganar HV. Se vuelve una advertencia metodológica: una métrica agregada puede premiar cobertura aunque el procedimiento sea poco razonado. Para




Figura 12: Costo estructural promedio medido como proporción de aristas modificadas.

defender un método de anonimización, necesitamos HV más costo, estabilidad, interpretabilidad y preservación de estructura. Esta es una de las lecciones metodológicas más importantes del reporte: una métrica agregada puede ordenar resultados, pero no sustituye la discusión. En particular, cuando el método modifica mucho el grafo, el hipervolumen debe leerse como cobertura del espacio de resultados, no automáticamente como calidad práctica.

X-F. Cambio promedio de aristas

La Figura 12 complementa directamente el hipervolumen. Aquí MOPPO aparece como el método más conservador. Esto es consistente con su mejor preservación de utilidad: si cambia pocas aristas, altera menos triángulos y menos clustering. Random Masked, en cambio, paga un costo muy alto. Greedy y Alpha-Greedy se sitúan en una zona intermedia, lo que sugiere que las heurísticas locales sí razonan sobre el costo de modificar, aunque no aprendan una política general. Esta diferencia también ayuda a explicar por qué conviene comparar familias de métodos distintas: el baseline aleatorio revela qué pasa cuando exploramos sin criterio fino; los greedy muestran el valor de una regla local; y

MOPPO permite estudiar la posibilidad de una política aprendida condicionada por preferencias.

X-G. Evolución de entrenamiento de MOPPO

La Figura 13 debe leerse sabiendo que la corrida del notebook es ligera. No busca reproducir las 500 u 800 iteraciones del paper, sino mostrar que el flujo completo funciona. Aun así, permite observar fluctuaciones propias de PPO: el método estima ventajas, actualiza por lotes y puede moverse de forma no monótona. En aprendizaje por refuerzo, una curva ruidosa no necesariamente indica fallo; puede indicar exploración, sensibilidad a la semilla o una recompensa con objetivos en conflicto. Lo que sí nos dice la figura es que una corrida corta debe interpretarse con cautela. PPO necesita suficientes iteraciones para estabilizar sus estimaciones de ventaja, y MOPPO además debe aprender varios comportamientos en un solo modelo.

X-H. Frentes de Pareto por método

La Figura 14 es especialmente valiosa porque separa el promedio de la geometría del problema. Dos métodos pueden tener scores parecidos y aun así cubrir regiones distintas. Fixed-alpha PPO produce varios puntos no dominados en esta corrida, lo que




Figura 13: Evolución de entrenamiento de MOPPO en la corrida del notebook.




Figura 14: Frentes de Pareto estimados por método.

puede parecer favorable. Pero debemos recordar que no representa una sola política adaptable: concep-




Figura 15: Regret empírico por preferencia α .

tualmente corresponde a preferencias fijas. Alpha-Greedy Rollout muestra varios puntos porque su decisión cambia con α . MOPPO, en esta corrida corta, aparece más concentrado; esto sugiere que el entrenamiento no fue suficiente para desplegar toda la flexibilidad que sí se esperaba del diseño. Aun así, la figura no debilita el planteamiento multi-objetivo; más bien señala con precisión dónde está el reto experimental: no solo entrenar una política, sino lograr que esa política ocupe regiones distintas del frente conforme cambia α .

X-I. Regret por α

El regret mide cuánto pierde cada método respecto al mejor método observado para un mismo α . Esta métrica es más justa que comparar promedios globales, porque reconoce que cada preferencia define un problema distinto. Si un método tiene bajo regret en $\alpha = 0$, conserva bien utilidad; si lo tiene en $\alpha = 1$, anonimiza bien. La Figura 15 permite ver en qué zonas cada método es competitivo y en cuáles queda rezagado.

Esta lectura es clave para la discusión del proyecto. No necesitamos que MOPPO gane todos los α para justificar MORL; necesitamos entender si puede sostener desempeño razonable en varias preferencias.

Si una heurística gana en una región, eso indica que esa región puede resolverse con reglas locales. Si MOPPO mejora con más entrenamiento en regiones mixtas, entonces el aprendizaje aporta adaptabilidad. Esta forma de leer el regret es más madura que buscar un ganador global, porque permite discutir fortalezas por región de preferencia. En aplicaciones reales, esa distinción importa: un usuario que prioriza utilidad no necesita el mismo comportamiento que un usuario que prioriza privacidad.

X-J. Estabilidad por semilla

La estabilidad por semilla ayuda a distinguir resultados robustos de resultados accidentales. Con solo dos semillas, no podemos afirmar significancia estadística fuerte, pero sí podemos observar sensibilidad. En métodos de RL, la semilla afecta inicialización de la red, muestreo de acciones y trayectorias recolectadas. En baselines heurísticos, la variación suele venir más de desempates o decisiones aleatorias. Por eso, si MOPPO varía más, no necesariamente significa que sea peor; significa que el entrenamiento aprendido introduce otra fuente de variabilidad que debe controlarse con más semillas. En un reporte final, reconocer esta limitación no resta valor al proyecto; al contrario,




Figura 16: Estabilidad del score por semilla.

muestra que la comparación fue leída con cuidado y que los resultados no se presentan como conclusiones definitivas sin respaldo estadístico suficiente.

X-K. Privacidad contra costo estructural

La Figura 17 responde una pregunta muy práctica: ¿cuánta privacidad compramos por cada cambio estructural? Un método que mejora privacidad modificando muchas aristas puede no ser deseable si el grafo debe conservar interpretabilidad. Random Masked muestra el extremo agresivo. MOPPO muestra el extremo conservador. Greedy y Alpha-Greedy permiten estudiar el punto medio: modifican menos que Random, pero mejoran privacidad más directamente que MOPPO en la corrida corta. Esta figura es útil para una defensa oral porque traduce el proyecto a una pregunta sencilla: ¿cuánto estamos pagando, en estructura, por cada mejora en privacidad?

X-L. Preservación de clustering por α

El clustering es una métrica de utilidad estructural porque captura triángulos y cohesión local. En redes sociales, los triángulos suelen representar comunidades o grupos cercanos. Si un método destruye clustering, puede conservar grados pero perder una propiedad social importante. La Figura 18 muestra

que MOPPO preserva muy bien esta dimensión, lo cual se alinea con su bajo costo de aristas. Random Masked, por modificar sin criterio estructural fino, tiende a deteriorarla más. La diferencia es relevante porque un grafo puede cumplir mejor una condición de anonimato y, aun así, dejar de representar adecuadamente la red social original. Por eso el clustering funciona como una señal de utilidad que complementa el conteo de aristas modificadas.

X-M. Heatmap método-alpha

El heatmap sintetiza el comportamiento completo de los métodos. Cada celda representa una pregunta: bajo esta preferencia, ¿qué tan bien funcionó este método? Visualmente, permite identificar zonas de fortaleza. Alpha-Greedy Rollout aparece como una referencia fuerte porque su regla está alineada con el score. Fixed-alpha PPO puede mejorar en puntos específicos, pero su interpretación es menos flexible. MOPPO requiere verse como política aprendida: si algunas celdas son débiles, la pregunta no es solo “perdió”, sino si la política recibió entrenamiento suficiente para discriminar preferencias.




Figura 17: Relación entre privacidad alcanzada y costo estructural.




Figura 18: Preservación del coeficiente de clustering promedio según α .

X-N. Trayectoria de privacidad

Las trayectorias paso a paso muestran lo que las métricas agregadas esconden. En la Figura 20,

cada punto representa el estado del grafo después de una acción. Un método greedy debería mejorar privacidad de forma más directa; un método aleatorio




Figura 19: Heatmap del score por método y preferencia α .




Figura 20: Evolución paso a paso de la recompensa de privacidad en un episodio de estudio.

puede tener saltos bruscos; MOPPO puede avanzar de forma más moderada. Esta figura es útil para explicar que la anonimización no ocurre de golpe, sino como una secuencia de decisiones. Esa lectura es central para aprendizaje por refuerzo: el valor de una acción no se entiende aislado, sino por la trayectoria que abre. Una modificación temprana puede facilitar

clases de grado futuras o, por el contrario, llevar al agente a un estado estructuralmente costoso.

$X-\tilde{N}$. Trayectoria de utilidad

La Figura 21 complementa la anterior. Un método puede mejorar privacidad y al mismo tiempo dañar utilidad. Observar ambas trayectorias permite




Figura 21: Evolución paso a paso de la utilidad estructural en un episodio de estudio.

detectar si el método sacrifica estructura de forma repentina o gradual. En problemas reales, esta diferencia importa: una estrategia que destruye utilidad al inicio puede no ser aceptable aunque termine con buena privacidad. Si el grafo anonimizado se usará para análisis de comunidades, recomendación o estudios de difusión, preservar utilidad durante la trayectoria también puede ser relevante, no solo al final del episodio.

X-O. Trayectoria de score

El score combina las dos trayectorias anteriores según α . Por eso puede subir aunque privacidad baje ligeramente, si utilidad mejora y α es bajo, o al revés. La Figura 22 ayuda a explicar por qué no existe una interpretación única de “mejor acción” sin conocer la preferencia. En MORL, la calidad de una decisión depende del usuario implícito representado por α .

X-P. Trayectoria de cambio de aristas

La Figura 23 muestra el costo acumulado de modificar el grafo. Este costo no es una métrica secundaria: es la forma más directa de medir cuánto nos alejamos de la red original. Un método que avanza en privacidad acumulando muchos cambios puede ser útil como exploración, pero no necesariamente

como método final. Por eso MOPPO, aun cuando no gana score global, conserva valor como estrategia prudente. La prudencia estructural no siempre luce como una victoria en tablas agregadas, pero puede ser deseable si el objetivo práctico es publicar una red anonimizada que todavía conserve propiedades sociales interpretables.

X-Q. Antes y después con Alpha-Greedy Rollout

La Figura 24 permite aterrizar el baseline nuevo. Alpha-Greedy Rollout no es solo una tabla de métricas: produce un grafo modificado paso a paso. Su valor como baseline está en que cada acción se justifica por el score del α actual. Así, si α favorece privacidad, acepta modificaciones que reduzcan déficit; si favorece utilidad, evita cambios costosos. Visualmente, el antes/después ayuda a revisar si la perturbación parece razonable o excesiva.

X-R. Distribución de grados antes y después

La Figura 25 conecta directamente con k -anonimato. La anonimización por grado busca reducir rarezas en la distribución. Si después de modificar el grafo varios grados tienen frecuencias más agrupadas, la privacidad por grado mejora. Sin embargo, no basta con agrupar grados: también




Figura 22: Evolución del score escalarizado durante el episodio.




Figura 23: Evolución del costo estructural acumulado.

debemos revisar qué aristas se cambiaron, cuánto clustering se perdió y si el costo se concentró en nodos periféricos.

XI. DISCUSIÓN INTEGRAL: LECTURA INTEGRADA DE LAS MÉTRICAS

XI-A. *Random Masked*, hipervolumen y costo estructural

Bajo la configuración experimental utilizada, *Random Masked* obtiene el mayor hipervolumen (HV =




Figura 24: Caso de estudio: grafo antes y después de aplicar Alpha-Greedy Rollout.




Figura 25: Distribución de grados antes y después del caso Alpha-Greedy Rollout.

0.9845). En una lectura superficial, esto podría sonar como una victoria clara. Pero el hipervolumen no pregunta cómo se llegó al frente; solo mide el área dominada por los puntos finales. Random Masked modifica muchas aristas, lo que puede llevarlo a regiones con buena privacidad. El problema es que esa estrategia no razona sobre utilidad y por eso obtiene el peor r_{util} promedio y el mayor costo estructural.

Esto nos deja una lección metodológica: en anonimización de grafos, una métrica agregada puede premiar soluciones agresivas. Por eso el reporte debe presentar hipervolumen junto con cambio de aristas, clustering y trayectorias. Si no lo hacemos, podríamos recomendar un método que anonimiza a costa de destruir la red.

XI-B. Alpha-Greedy Rollout como baseline multi-objetivo

Alpha-Greedy Rollout obtiene el mejor score ponderado promedio (-0.0225). Este resultado es coherente con su diseño. A diferencia de Greedy Liu-Terzi style, que se centra en privacidad, Alpha-Greedy evalúa cada acción con el mismo α del episodio. Por eso responde de forma más natural al problema multi-objetivo. En cierto sentido, Alpha-Greedy Rollout es un rival más justo para MOPPO que un greedy puramente privado.

Su fortaleza también marca una exigencia para MOPPO: si una heurística local puede aproximar bien el trade-off en un grafo pequeño, el agente aprendido debe justificar su complejidad mostrando adaptabilidad, escalabilidad o mejor comportamiento en grafos más grandes. Esta es una discusión honesta y académicamente más sólida que decir simplemente que RL es superior.

XI-C. MOPPO y la importancia de la adaptabilidad

MOPPO fue el método más conservador estructuralmente y el que mejor preservó utilidad promedio. Esto puede interpretarse de dos formas. Una lectura crítica diría que el agente fue demasiado prudente y no exploró suficientes modificaciones para mejorar privacidad. Una lectura favorable diría que aprendió a no destruir estructura, que es justamente una parte importante del problema. Ambas lecturas pueden coexistir.

La clave es distinguir entre el diseño conceptual y la corrida experimental. El diseño de MOPPO busca aprender una política condicionada por preferencias. Para demostrarlo con fuerza se necesitan más iteraciones, más semillas y grafos de distinta dificultad. El notebook *Baseline Comparison RL-MOPPO* utiliza una configuración ligera para privilegiar reproducibilidad y lectura experimental. Por eso sus resultados deben entenderse como evidencia exploratoria y comparativa, no como conclusión definitiva de rendimiento.

XI-D. La privacidad promedio y el papel del greedy clásico

Greedy Liu-Terzi style obtiene la mejor privacidad promedio ($r_{\text{priv}} = -0.0250$). Esto es esperable porque su regla está alineada con corregir clases de grado. En problemas donde solo importa anonimato por grado, una heurística de este tipo puede ser suficiente. Pero el proyecto no trata únicamente de privacidad; trata de privacidad bajo costo estructural y bajo preferencias variables. Por eso Greedy Liu-Terzi style es un baseline necesario, pero no reemplaza el enfoque multi-objetivo.

XI-E. Equidad: el costo no se reparte igual

El paper base reporta que los nodos periféricos tienden a absorber más impacto relativo que los hubs. Esta observación es importante porque desplaza la discusión desde el promedio hacia la distribución del daño. Dos métodos pueden tener el mismo número de aristas modificadas, pero afectar de forma muy distinta a los nodos. Si los cambios se concentran en la periferia, el método puede reforzar una desigualdad estructural: los nodos con menor conectividad pagan más por la privacidad global del grafo.

Una extensión natural sería agregar una penalización explícita de equidad:

$$r_{\text{fair}} = r - \lambda_{eq} \max(0, \Delta - \Delta^*). \quad (8)$$

Esto convertiría el problema en una formulación de tres objetivos: privacidad, utilidad y equidad. Desde el punto de vista del curso, esta extensión es muy valiosa porque muestra cómo una recompensa puede ampliarse para incorporar criterios sociales o éticos, no solamente técnicos.

XII. RELACIÓN ENTRE MÓDULOS DEL REPOSITORIO Y ANÁLISIS EXPERIMENTAL

El repositorio organiza el proyecto en scripts de entrenamiento, evaluación, generación de figuras y módulos del ambiente. El README describe que `train_main.py` entrena MOPPO o baselines PPO, `evaluate.py` calcula Pareto, TREX y fairness, `make_comparison_figs.py` genera figuras comparativas, y la carpeta `graph_anon_morl`

Cuadro IV: Relación entre módulos del repositorio y secciones del notebook *Baseline Comparison RL-MOPPO*.

Componente	Función dentro del proyecto
env.py / GraphAnonEnv	Define el MDP: estado del grafo, acciones tipo <i>flip</i> , máscara de acciones válidas, transición y recompensas. En el notebook se conserva esta lectura del ambiente para mantener coherencia con el proyecto.
models.py / MOPPOActorCritic / train_main.py	Define la red actor-crítico condicionada por α . En el notebook se conserva la idea de actor con logits sobre acciones y crítico escalar. Ejecuta entrenamiento PPO/MOPPO, con curriculum o con α fijo. En el análisis comparativo aparece como referencia para entender la diferencia entre MOPPO y PPO de preferencia fija.
evaluation.py	Calcula frentes no dominados e hipervolumen. El notebook incluye funciones equivalentes para comparar métodos con el mismo lenguaje de métricas.
audit.py	Mide disparidad de impacto por cuartil de grado. En el reporte se discute como línea central para hablar de equidad y costo desigual de anonimización.
trex.py	Agrupar trayectorias para analizar si el condicionamiento por pesos produce comportamientos diferenciados.
outputs/figures	Contiene figuras del paper base: entrenamiento, frentes, TREX, equidad e hipervolumen.
notebooks/baseline_comparison	Base conceptual para comparar métodos; el notebook <i>Baseline Comparison RL-MOPPO</i> lo extiende con más gráficas, semillas y el baseline Alpha-Greedy Rollout.

contiene el ambiente, modelo, evaluación, auditoría, TREX, utilidades y datasets.

El notebook *Baseline Comparison RL-MOPPO* se diseñó como una extensión experimental del proyecto. Su estructura sigue la arquitectura del repositorio RL-MOPPO: primero se define el ambiente, después la política, luego el entrenamiento y finalmente la evaluación con métricas multi-objetivo. Esta correspondencia es importante porque evita que el notebook sea una comparación aislada; en realidad funciona como una lectura ejecutable del mismo diseño metodológico.

Por qué fue útil concentrar el análisis en un notebook de comparación: El repositorio es adecuado para desarrollo, organización modular y reproducción del proyecto completo. El notebook *Baseline Comparison RL-MOPPO*, en cambio, cumple una función comunicativa: concentra la comparación en una narrativa experimental lineal. Primero muestra qué grafo se está anonimizando, luego explica cómo actúa cada método, después cuantifica privacidad, utilidad y costo, y finalmente traduce esos números en gráficas interpretables. Esa organización ayuda a que la evaluación no sea solo una tabla de métricas, sino una explicación de comportamiento.

XIII. DISCUSIÓN AMPLIADA DEL ENFOQUE

Esta sección reúne la lectura que consideramos más importante del proyecto. La comparación experimental no debe entenderse como una competencia

simple entre métodos, sino como una forma de estudiar distintas maneras de intervenir un grafo. Cada algoritmo tiene una forma particular de “pensar” el problema: algunos exploran, otros corrigen déficits de grado, otros preservan estructura y MOPPO intenta aprender una política que responda a preferencias variables. Por eso, más que buscar una frase como “el mejor método es...”, nos parece más honesto explicar qué tipo de comportamiento produce cada método y qué significa ese comportamiento para anonimización de redes.

XIII-A. Una sola métrica no alcanza

El primer aprendizaje del proyecto es que una métrica aislada puede ser insuficiente, e incluso engañosa, si no se acompaña de una interpretación estructural. El hipervolumen es una métrica fuerte en optimización multi-objetivo porque resume el área dominada por un conjunto de soluciones. Sin embargo, no sabe distinguir entre una solución que llegó al frente con perturbaciones cuidadosas y otra que lo hizo modificando muchas aristas sin criterio fino. En nuestros resultados, Random Masked obtuvo el mayor hipervolumen, pero también presentó el costo estructural más alto. Esa combinación no debe leerse como contradicción; al contrario, muestra exactamente por qué el reporte necesita varias gráficas.

En una aplicación real, publicar un grafo anonimizado implica una responsabilidad doble. Por un lado, queremos reducir señales de reidentificación;

por otro, no queremos publicar una red que ya no represente el fenómeno original. Si una red social se usa para estudiar comunidades, difusión de información o centralidad de actores, destruir clustering puede volver inútil el resultado, aunque la privacidad mejore. Por eso insistimos en mirar simultáneamente privacidad, utilidad, cambio de aristas, clustering, regret y estabilidad por semilla. La calidad de una anonimización no es solamente qué tan privado quedó el grafo, sino qué tanto sentido conserva después de la intervención.

XIII-B. Qué aporta MOPPO dentro de esta comparación

MOPPO no debe defenderse con la idea de que siempre gana. De hecho, los resultados del notebook muestran un panorama más matizado: en una corrida ligera, MOPPO fue el método más conservador estructuralmente, pero no el de mayor hipervolumen ni el de mejor score promedio. Para nosotros, esto no debilita el proyecto; lo vuelve más claro. MOPPO está diseñado para aprender una política condicionada por preferencias, y esa capacidad necesita suficiente entrenamiento para desplegarse. Cuando el presupuesto de entrenamiento es corto, el agente puede aprender una estrategia prudente: modificar poco, preservar clustering y evitar perturbaciones agresivas.

Esa prudencia tiene valor. En problemas de privacidad, un método agresivo puede producir resultados impresionantes en una tabla, pero difíciles de justificar si daña demasiado la red. MOPPO, al conservar estructura, muestra una lectura más cuidadosa del ambiente. La pregunta experimental que queda abierta no es si MOPPO “sirve” o “no sirve”, sino bajo qué presupuesto de entrenamiento y bajo qué escala de grafo empieza a superar de forma clara a heurísticas locales. Esta es una pregunta legítima de aprendizaje por refuerzo: un agente aprendido tiene costos de entrenamiento, pero puede aportar adaptabilidad cuando las reglas simples dejan de ser suficientes.

También es importante que MOPPO trabaja con una sola política condicionada por α . Los baselines de alpha fijo pueden comportarse bien en su zona, pero no están diseñados para adaptarse a preferencias cambiantes. En un escenario práctico, donde

una institución puede requerir distintos niveles de privacidad para distintos usos, entrenar o seleccionar una política distinta por cada preferencia puede ser menos conveniente que disponer de un modelo condicionado.

XIII-C. Por qué los baselines fortalecen el reporte

La incorporación de baselines no se hizo solo para llenar una tabla. Cada baseline cumple una función interpretativa. Random Masked sirve como control inferior: nos muestra qué pasa cuando se respetan acciones válidas, pero no se razona sobre el balance privacidad-utilidad. Greedy Liu-Terzi style representa la intuición clásica de anonimización por grado: corregir clases deficientes de forma local. Alpha-Greedy Rollout, por su parte, es una referencia más exigente para MOPPO porque usa el mismo α del episodio para decidir cada acción.

Este último baseline es especialmente útil. Si Alpha-Greedy Rollout obtiene buen score, significa que una heurística local alineada con la función de evaluación puede ser muy competitiva en grafos pequeños. Esto obliga a MOPPO a demostrar su valor en dimensiones donde el greedy no necesariamente escala: adaptación, cobertura del frente, generalización a grafos más grandes y comportamiento estable ante preferencias variables. En otras palabras, los baselines no debilitan el proyecto; elevan el estándar de comparación y hacen que la discusión sea más sólida.

Desde una perspectiva académica, esta comparación también evita una conclusión artificial. Habría sido menos honesto presentar MOPPO como ganador absoluto. La versión más defendible es reconocer que cada método gana algo distinto: Random Masked gana área dominada, Greedy gana privacidad promedio, Alpha-Greedy gana score ponderado y MOPPO gana prudencia estructural. Precisamente por eso el problema es multi-objetivo.

XIII-D. Interpretación humana del proceso de anonimización

Una parte que consideramos importante del reporte es mirar las trayectorias paso a paso. Las tablas resumen el resultado final, pero las trayectorias muestran el proceso. En aprendizaje por refuerzo, esto importa porque el agente no produce una

solución de una sola vez; construye una secuencia de decisiones. Cada acción cambia el grafo, y ese cambio modifica las posibilidades futuras.

Esta idea hace que el problema sea más intuitivo. Anonimizar no es apretar un botón y obtener privacidad. Es decidir qué arista tocar, aceptar que esa decisión cambia dos grados, observar si se formó o rompió un triángulo, y repetir el proceso. Por eso las trayectorias de privacidad, utilidad, score y cambio de aristas ayudan a contar la historia completa. Un método puede mejorar privacidad en pocos pasos, pero destruir utilidad; otro puede avanzar más lentamente, pero conservar mejor la red. La diferencia entre ambos comportamientos no siempre aparece en una tabla promedio.

La visualización antes/después con Alpha-Greedy Rollout también cumple esta función. Permite aterrizar la discusión: no estamos comparando números abstractos, sino transformaciones concretas de una red. Al ver cómo cambian las aristas y cómo se agrupan los grados, se entiende mejor por qué el costo estructural importa. Esta es una forma más natural de explicar el proyecto sin perder rigor técnico.

XIII-E. Implicaciones para trabajo futuro

El proyecto deja varias rutas claras. La primera es aumentar el presupuesto experimental: más iteraciones, más semillas y más grafos. Esto permitiría distinguir con mayor confianza cuándo MOPPO está limitado por entrenamiento corto y cuándo una heurística local realmente domina una región del problema. La segunda es ampliar la noción de utilidad. El clustering es una señal importante, pero una red social también puede evaluarse por modularidad, centralidades, caminos promedio, componentes y preservación de comunidades. La tercera es incorporar equidad dentro de la recompensa. El índice Δ ya muestra que el costo de anonimización no se reparte igual entre nodos periféricos y hubs; el siguiente paso es que el agente no solo mida esa disparidad, sino que aprenda a evitarla.

Finalmente, la escalabilidad requiere rediseñar el espacio de acciones. Una política plana sobre todos los pares de nodos crece de forma cuadrática. Para grafos grandes, una arquitectura jerárquica sería más razonable: primero elegir un nodo en riesgo

y después elegir la arista concreta. Esta extensión mantendría la idea de MOPPO, pero la haría más viable para redes de mayor tamaño.

En síntesis, el valor del proyecto no está solo en los resultados numéricos, sino en la forma de análisis que propone. MOPPO, los baselines y las gráficas construyen juntos una lectura más completa de la anonimización: proteger una red implica decidir cuánto cambiar, dónde cambiar y con qué costo social y estructural.

XIV. LIMITACIONES

XIV-A. Número de semillas

La corrida del notebook utiliza dos semillas. Esto es suficiente para mostrar reproducibilidad mínima y generar gráficas, pero no para afirmar conclusiones estadísticas fuertes. Una versión final de investigación debería usar al menos 5 o 10 semillas, reportar intervalos de confianza y separar variabilidad por entrenamiento de variabilidad por evaluación.

XIV-B. Presupuesto de entrenamiento

La configuración del notebook fue pensada para una corrida ligera y reproducible. Por ello, el número de iteraciones de MOPPO y Fixed-alpha PPO es menor que en el paper base. Esta limitación afecta especialmente a MOPPO, porque una política condicionada por pesos necesita aprender varios comportamientos dentro de un solo modelo. Si el entrenamiento es corto, puede quedarse en una política conservadora.

XIV-C. Escalabilidad

El espacio de acciones crece como $O(n^2)$. Aunque el action masking reduce el espacio efectivo, el actor todavía produce logits para todas las acciones. Para grafos grandes, convendría una política jerárquica: primero elegir un nodo objetivo y después elegir con qué nodo modificar la arista. Esto convertiría una decisión cuadrática en dos decisiones aproximadamente lineales.

XIV-D. Utilidad estructural parcial

El clustering promedio es una métrica útil, pero no captura toda la estructura. Una red social también tiene comunidades, centralidades, caminos cortos,

modularidad y distribución de componentes. Un método podría preservar clustering y aun así alterar comunidades. Por eso futuras versiones deberían agregar más métricas de utilidad.

XIV-E. *Equidad todavía descriptiva*

El índice Δ diagnostica disparidad, pero no la corrige. El siguiente paso natural es incorporar equidad en la recompensa o como restricción. Esta extensión haría el proyecto más sólido porque convertiría un hallazgo crítico en una decisión algorítmica explícita.

XV. TRABAJO FUTURO

1. **Más semillas y más iteraciones.** Repetir el notebook con 10 semillas y entrenamientos más largos para separar tendencias de ruido.
2. **Extensión a grafo Facebook dentro del análisis comparativo.** Agregar una versión del notebook con subgrafo sintético o cargar el dataset si está disponible, para comparar escala.
3. **Métricas estructurales adicionales.** Reportar modularidad, centralidad, distancia promedio y distribución de componentes.
4. **Equidad como tercer objetivo.** Penalizar el índice Δ o imponer un umbral máximo de disparidad.
5. **Política jerárquica.** Dividir la acción en selección de nodo y selección de arista para escalar a grafos más grandes.
6. **Comparación con algoritmos clásicos completos.** Implementar una versión más fiel de Liu-Terzi y otros métodos de anonimización por vecindario.
7. **Ablation study.** Quitar action masking, quitar curriculum y quitar conditioning para medir qué contribución explica cada mejora.

XVI. CONCLUSIÓN

Este proyecto nos permitió estudiar la anonimización de grafos como una negociación entre objetivos. La formulación MORL es adecuada porque la privacidad no vive sola: cada mejora puede tener un costo en utilidad, estructura y equidad. MOPPO propone una política condicionada por preferencias para recorrer esa negociación, apoyándose en action

masking y curriculum learning para hacer entrenable un espacio de acciones grande y conflictivo.

El paper base mostró que MOPPO puede construir frentes de Pareto, conservar cobertura multi-objetivo y revelar sesgos de equidad. El notebook *Baseline Comparison RL-MOPPO* fortaleció la parte comparativa: agregó baselines, semillas, gráficas, trayectorias y una heurística nueva, Alpha-Greedy Rollout. Los resultados fueron más matizados de lo que esperábamos, y eso mejora el reporte. Random Masked ganó hipervolumen, pero con alto costo estructural. Greedy Liu-Terzi style ganó privacidad promedio, como era esperable. Alpha-Greedy Rollout ganó score ponderado promedio, mostrando que un baseline local alineado con α puede ser muy fuerte. MOPPO fue el más conservador y el que mejor preservó utilidad, aunque necesita más entrenamiento para desplegar plenamente su ventaja multi-objetivo.

Nuestra conclusión final es que no hay un ganador universal. Hay métodos que protegen más, métodos que conservan más, métodos que exploran más y métodos que se adaptan mejor a la preferencia. Precisamente por eso el enfoque multi-objetivo es pertinente: porque obliga a mirar el frente completo y no solamente un número. En una red social real, elegir una política de anonimización no es una decisión puramente técnica; es decidir qué tipo de daño estamos dispuestos a aceptar para obtener cierto nivel de privacidad.

XVII. GUION DE DISCUSIÓN PARA EXPOSICIÓN ORAL

Bajo la configuración experimental utilizada, el método con mayor hipervolumen fue Random Masked, con $HV = 0.9845$. Esto indica que produjo un conjunto de soluciones que domina una región amplia del plano privacidad-utilidad. Sin embargo, este resultado no debe interpretarse como una victoria absoluta, porque Random Masked también fue el método con mayor cambio promedio de aristas. En otras palabras, logra cobertura, pero pagando un costo estructural alto.

En términos de privacidad promedio, el mejor método fue Greedy Liu-Terzi style. Esto es coherente con su diseño, porque está orientado a corregir clases de grado deficientes. Por otro lado, la mejor preservación de utilidad estructural correspondió a

Cuadro V: Checklist de lectura de las figuras del reporte.

Figura	Qué demuestra
Grafo original	Muestra la estructura relacional que será perturbada.
Distribución de grados	Identifica grados raros y clases vulnerables para k -anonimato.
Privacidad-utilidad	Ubica métodos en el plano central del problema.
Score por α	Evalúa adaptación a preferencias.
Hipervolumen	Resume área dominada, pero requiere lectura con costo.
Cambio de aristas	Mide cuánto se aleja el grafo del original.
Entrenamiento MOPPO	Muestra dinámica y ruido de PPO.
Frentes por método	Distingue cobertura del frente de desempeño promedio.
Regret	Compara métodos por preferencia, no solo globalmente.
Estabilidad por seed	Identifica sensibilidad experimental.
Privacidad vs costo	Muestra eficiencia de perturbación.
Clustering	Evalúa preservación de utilidad estructural.
Heatmap	Resume método contra preferencia.
Trayectorias	Explican el comportamiento paso a paso.
Antes/después	Aterrizo visualmente el efecto de un baseline.
Distribución antes/después	Verifica cómo se agrupan grados tras anonimizar.

MOPPO, que mantuvo el cambio promedio de aristas más bajo y la menor desviación de clustering. Esto sugiere que la política aprendida fue conservadora.

El resultado más interesante del notebook es Alpha-Greedy Rollout. Este baseline obtuvo el mejor score ponderado promedio porque usa el mismo α de evaluación para decidir cada acción. Por eso se comporta como una línea base multi-objetivo razonable: no maximiza privacidad de forma ciega ni preserva utilidad de forma absoluta, sino que negocia según la preferencia.

En conjunto, la comparación separa dos fenómenos: optimizar bien una preferencia local y aprender una política adaptable. Si un baseline greedy domina en algunos valores de α , eso no invalida el enfoque de RL; más bien identifica regiones donde una regla local basta. La promesa de MOPPO está en escenarios donde las preferencias cambian, donde el grafo es más grande y donde necesitamos una política que no solo resuelva un punto, sino que aprenda a navegar el frente.

XVIII. CHECKLIST DE LECTURA DE FIGURAS

REFERENCIAS

- [1] Abels, A., Roijers, D., Lenaerts, T., Nowé, A., & Steckelmacher, D. (2019). Dynamic weights in multi-objective deep reinforcement learning. *ICML*, 11–20.
- [2] Chester, S., Kapron, B. M., Ramesh, G., Srivastava, G., Thomo, A., & Venkatesh, S. (2013). Why Waldo befriended the dummy? *Social Network Analysis and Mining*, 3(3), 381–399.
- [3] Gao, M., Chen, L., He, X., & Zhou, A. (2022). Reinforcement learning for graph anonymization. *IEEE Transactions on Knowledge and Data Engineering*, 34(8).
- [4] Hung, C., & Chen, C. (2022). Multi-objective reinforcement learning for traffic signal control. *Transportation Research Part C*, 142, 103799.
- [5] Leskovec, J., & McAuley, J. (2012). Learning to discover social circles in ego networks. *NeurIPS* 25.
- [6] Liu, K., & Terzi, E. (2008). Towards identity anonymization on graphs. *ACM SIGMOD*, 93–106.
- [7] Mauw, S., Ramirez-Cruz, Y., & Trujillo-Rasua, R. (2021). Anonymizing graphs: measuring quality for clustering. *Knowledge and Information Systems*, 63, 2365–2397.
- [8] Yang, R., Sun, X., & Narasimhan, K. (2019). A generalized algorithm for multi-objective reinforcement learning and policy adaptation. *NeurIPS* 32.
- [9] You, J., Liu, B., Ying, Z., Pande, V., & Leskovec, J. (2018). Graph convolutional policy network for goal-directed molecular graph generation. *NeurIPS* 31.
- [10] Zachary, W. W. (1977). An information flow model for conflict and fission in small groups. *Journal of Anthropological Research*, 33(4), 452–473.

- [11] Zhou, B., & Pei, J. (2008). Preserving privacy in social networks against neighborhood attacks. *IEEE ICDE*, 506–515.
- [12] Zhou, Z., Li, J., Glass, M., Marple, P., & Chen, S. (2019). Network architecture search for generative adversarial networks. *ICCV*.
- [13] Zitzler, E., & Thiele, L. (1999). Multiobjective evolutionary algorithms: a comparative case study. *IEEE Transactions on Evolutionary Computation*, 3(4), 257–271.