

moppo: Aprendizaje por Refuerzo Multi-Objetivo con Curriculum Learning para Anonimizacion de Grafos

Analisis de equidad mediante TREX y auditoria por cuartil de grado

Abril Minerva Estrada Montano

Licenciatura en Ciencia de Datos
abrilminerva@gmail.com

Sebastian Alanis Gonzalez

Licenciatura en Ciencia de Datos
sebastian.alanis@gmail.com

Junio 2026

Resumen

Anonimizar una red social sin destruir su estructura es un problema de optimizacion con dos objetivos que se oponen: mientras mas privado queda el grafo, mas se aleja de su topologia original. Nosotros formulamos esto como un problema de aprendizaje por refuerzo multi-objetivo (MORL) y entrenamos un agente PPO condicionado por pesos para navegar ese balance de manera adaptativa. El resultado es MOPPO, un framework que aprende politicas para cualquier preferencia privacidad/utilidad con un solo modelo, en lugar de entrenar uno diferente por cada punto del frente de Pareto. Introducimos dos contribuciones tecnicas: *action masking* basado en deficit de k -anonimato, que reduce el espacio efectivo de acciones entre $25\times$ y $45\times$, y un curriculum en tres fases que resuelve la inestabilidad de gradientes contrapuestos en el entrenamiento temprano. Evaluamos sobre el grafo de karate club ($k = 2, k = 4$) y un subgrafo de ego de Facebook con 100 nodos, alcanzando hipervolumenes de 0.973, 0.388 y 0.897 respectivamente. Ademas documentamos un sesgo de equidad sistematico: los nodos perifericos absorben entre $2,1\times$ y $3,9\times$ mas impacto relativo que los hubs durante la anonimizacion, independientemente del valor de α .

Palabras clave: anonimizacion de grafos, aprendizaje por refuerzo multi-objetivo, PPO, curriculum learning, k -anonimato, equidad algoritmica.

1. Introduccion

La privacidad en redes sociales lleva mas de una decada siendo estudiada, pero el problema practico sigue abierto. Los algoritmos clasicos de anonimizacion, como el esquema de grados de Liu y Terzi [2008], estan disenados para minimizar cambios estructurales con una funcion de costo fija, sin preguntarse que tipo de perturbaciones son mas aceptables segun el contexto. No hay preferencia configurable, no hay balance explicito entre objetivos.

Nosotros partimos de una premisa distinta. La decision de cuanta privacidad comprar a que costo en utilidad es contextual: un sistema de salud necesita maxima privacidad aunque pierda estructura de red; una plataforma de recomendaciones no puede permitirse perder clustering. Dado que ese balance varia por caso de uso, tiene sentido aprender a navegar todo el frente de Pareto en lugar de resolver un unico punto.

El aprendizaje por refuerzo multi-objetivo (MORL) es el marco natural para esto. Condicionamos la politica por un vector de pesos $\alpha \in [0, 1]$ que representa la preferencia entre privacidad y utilidad; el agente aprende a adaptar su comportamiento segun ese vector. En la practica hay dos obstaculos: el espacio de acciones en un grafo de n nodos tiene $\binom{n}{2} + 1$ posibilidades (4,951 para $n = 100$), y aprender ambos objetivos desde cero genera gradientes contrapuestos que desestabilizan el entrenamiento.

Las contribuciones de este trabajo son: (i) formulacion

de la anonimizacion de grafos como MDP multi-objetivo con weight conditioning; (ii) action masking por deficit de k -anonimato que reduce el espacio efectivo $25\text{--}45\times$; (iii) curriculum en tres fases que estabiliza el entrenamiento; (iv) auditoria de equidad sistematica con el indice Δ y analisis TREX.

2. Trabajo relacionado

Anonimizacion de grafos. Liu y Terzi [2008] proponen modificar la secuencia de grados para lograr k -anonimato con el minimo numero de cambios de aristas. Zhou y Pei [2008] extienden esto a vecindarios. Ambos son metodos deterministicos con un unico objetivo. Chester et al. [2013] demuestran que el problema es NP-hard en el caso general. Mauw et al. [2021] destacan que la mayoria de los metodos ignoran quien dentro del grafo paga el costo de la anonimizacion, lo que nosotros medimos con Δ .

RL para grafos. You et al. [2018] y Zhou et al. [2019] usan RL para generacion molecular y sintesis de redes. Para anonimizacion, Gao et al. [2022] proponen un DQN con recompensa binaria de privacidad, sin considerar utilidad.

MORL y weight conditioning. Abels et al. [2019] proponen weight conditioning para redes Q; Yang et al. [2019] lo extienden con envelope MORL. Hung y Chen [2022] aplican weight conditioning a PPO para planificacion. Nosotros

adaptamos este paradigma a la modificación de grafos y agregamos action masking y curriculum.

3. Formulación del problema

Sea $G_0 = (V, E_0)$ con $n = |V|$ nodos. Un grafo G es k -anonimo por grado si:

$$\forall v \in V : |\{u : \deg_G(u) = \deg_G(v)\}| \geq k. \quad (1)$$

Recompensas.

$$r_{\text{priv}}(G) = -\frac{1}{n} \sum_v \max(0, k - |\text{clase}(v)|) \quad (2)$$

$$r_{\text{util}}^{\text{proxy}} = -|\text{aristas neto modificadas}| / |E_0| \quad (3)$$

$$r_{\text{util}}^{\text{real}} = -|C(G) - C(G_0)| \quad (4)$$

donde $C(\cdot)$ es el coeficiente de clustering promedio. La recompensa escalar es:

$$r = \alpha \cdot r_{\text{priv}} + (1-\alpha) \cdot r_{\text{util}}^{\text{proxy}}, \quad \alpha \in [0, 1]. \quad (5)$$

Observacion. $s \in \mathbb{R}^{2n+2}$: grados normalizados, deficit de anonimato por nodo, y vector $[\alpha, 1-\alpha]$.

Acciones. $\mathcal{A} = \{\text{flip}(u, v) : u < v\} \cup \{\text{no-op}\}$, $|\mathcal{A}| = \binom{n}{2} + 1$.

4. Metodología

4.1. Arquitectura del modelo

Red actor-crítico con dos capas lineales de d_h unidades (tanh), cabeza de actor sobre $|\mathcal{A}|$ acciones y cabeza crítica escalar. Inicialización ortogonal: ganancia 0.01 para el actor, 1.0 para el crítico. El vector α entra concatenado al estado en cada paso.

4.2. Enmascaramiento de acciones

Calculamos los nodos en riesgo: $\mathcal{R}_t = \{v : |\text{clase}(v)| < k\}$. Solo son válidas las aristas incidentes en $\mathcal{R}_t$ y la acción no-op:

$$\mathcal{A}_t^{\text{valid}} = \{\text{flip}(u, v) : u \in \mathcal{R}_t \text{ o } v \in \mathcal{R}_t\} \cup \{\text{no-op}\}. \quad (6)$$

Las acciones inválidas reciben logit -10^9 . La máscara se almacena en el buffer de rollout y se reaplica durante el update de PPO — paso crítico: si se omite, los ratios $\exp(\log \pi_\theta - \log \pi_{\theta_{\text{old}}})$ son incorrectos y el entrenamiento diverge.

4.3. Curriculum Learning

En la Fase 1 el agente aprende que aristas flippear para mejorar k -anonimato. En la Fase 2 aprende que con $\alpha \approx 0$ la política óptima es mayoritariamente no-op. En la Fase 3 interpola entre los comportamientos ya aprendidos, eliminando la ambigüedad de gradientes contrapuestos.

Cuadro 1: Fases del curriculum.

Fase	Iters	Distribución de α
1 — Privacidad	$[0, T_1)$	$\mathcal{U}(0, 95, 1, 0)$
2 — Utilidad	$[T_1, T_2)$	$\mathcal{U}(0, 00, 0, 05)$
3 — Mixto	$[T_2, T)$	$\mathcal{U}(0, 1)$

4.4. Actualización PPO

PPO con clipping ($\varepsilon = 0,2$), ventaja normalizada, 4 épocas por rollout, $\beta_{\text{ent}} = 0,05$, GAE ($\gamma = 0,99$, $\lambda = 0,95$), 512 pasos por iteración, Adam ($\text{lr} = 3 \times 10^{-4}$), clip de gradiente en 0.5.

4.5. Análisis de equidad con TREX

El índice de disparidad compara la pérdida de aristas entre cuartiles de grado:

$$\Delta = \frac{\text{pérdida normalizada}_{Q_1}}{\text{pérdida normalizada}_{Q_4}}. \quad (7)$$

$\Delta = 1$ es equitativo; $\Delta > 1$ indica que los nodos periféricos pagan más.

El análisis TREX [Rajapakse et al., 2026] corre 30 episodios con α aleatorio, registra el perfil acumulado de recompensas y aplica k -means ($k = 3$). Si los clusters se separan por α , el weight conditioning funciona correctamente.

5. Experimentos

5.1. Configuraciones

Evaluamos en: karate club [Zachary, 1977] ($n = 34$, $k = 2$ y $k = 4$) y un subgrafo de ego de Facebook [Leskovec y McAuley, 2012] ($n = 100$, $k = 2$). Hiperparámetros: $T = 50$ pasos/episodio, semilla 42, $d_h = 128$ (karate) y $d_h = 256$ (Facebook), 500 iters (karate) y 800 iters (Facebook).

5.2. Métrica principal: hipervolumen

$$\text{HV}(\mathcal{F}, \mathbf{r}) = \lambda \left(\bigcup_{p \in \mathcal{F}} [p, \mathbf{r}] \right), \quad \mathbf{r} = (-1, -1). \quad (8)$$

Evaluamos 21 valores de $\alpha \in [0, 1]$, 15 episodios cada uno.

5.3. Baselines

Tres variantes de PPO con α fijo y sin curriculum: $\alpha = 0$ (utilidad pura), $\alpha = 0,5$ (escalarización fija), $\alpha = 1$ (privacidad pura). Cada baseline entrena un modelo separado y solo es competitivo en su α específico.

6. Resultados

6.1. Curvas de entrenamiento

La Figura 1 muestra que la Fase 1 produce la mejora más rápida en las tres configuraciones. Para karate $k = 2$ la recompensa pasa de $-0,042$ a $-0,007$ (mejora del 83.5%). Las transiciones entre fases son suaves, sin caídas abruptas que




Figura 1: Curvas de convergencia suavizadas (ventana 10 iters). Las líneas punteadas verticales marcan las transiciones entre fases. El panel derecho muestra el hipervolumen final por configuración.

indicarian olvido catastrófico. La Fase 2 es la más estable (menor desviación estándar en todas las configuraciones), lo que confirma que el agente ya sabe hacer no-op desde la Fase 1.

6.2. Frentes de Pareto

La Figura 2 muestra los tres frentes. En karate $k = 2$ el frente degenera a un punto porque el modelo alcanza k -anonimato perfecto para todos los α ; la variación está solo en utilidad ($r_{\text{util}} \in [-0,042, -0,027]$). Karate $k = 4$ muestra el tradeoff más claro: tres puntos con rango de 0.202 en r_{priv} . Facebook $n = 100$ produce el frente más rico: seis puntos con distribución de colores que confirma el weight conditioning.

6.3. Análisis TREX

El weight conditioning separa los clusters en ambas configuraciones. Para karate $k = 4$: α promedio de 0.23, 0.43 y 0.76. Para Facebook: 0.46, 0.55 y 0.61 — separación más difusa, coherente con el menor número de iteraciones relativo al tamaño del problema.

6.4. Equidad

El sesgo de equidad no es exclusivo de MOPPO: todos los métodos superan el umbral Rawls en $k = 4$ y Facebook. PPO $\alpha = 0$ es el más equitativo en $k = 2$ porque apenas modifica el grafo. El hallazgo transversal es que la anonimización de grafos tiene un sesgo estructural: juntar clases de equivalencia de grado en los extremos inferiores de la distribución es computacionalmente más barato, por lo que cualquier método sin restricción explícita de equidad exhibirá la misma conducta.

6.5. Sensibilidad al peso α

Calculamos la correlación de Spearman entre α asignado y r_{priv} final sobre los 30 episodios TREX. Para karate $k = 4$: $\rho = +0,41$ ($p < 0,05$). Para Facebook: $\rho = +0,29$ ($p < 0,10$). Los baselines de α fijo tienen $\rho = 0$ por construcción. Esta correlación positiva es la diferencia cualitativa que el HV escalar no captura: MOPPO es adaptable; los baselines son políticas fijas.

6.6. Comparación con baselines

La Tabla 2 y la Figura 5 revelan un patrón consistente: ningún método domina en HV en todos los escenarios, pero MOPPO es el único que produce sistemáticamente el mayor número de puntos Pareto (1, 3 y 6 frente a un máximo de 1, 2 y 4 para cualquier baseline).

Para karate $k = 2$, MOPPO tiene el HV más alto (0.9727), aunque el margen es pequeño porque el problema es trivial para todos. Para karate $k = 4$, PPO $\alpha = 1,0$ supera a MOPPO en HV (0.493 vs 0.388), lo que interpretamos como un límite de convergencia: 500 iters son insuficientes para este régimen difícil, mientras que un modelo single-objective converge más rápido. Para Facebook, PPO $\alpha = 0$ obtiene el HV más alto (0.9036 vs 0.8968) porque la política de utilidad pura evita modificaciones costosas en un grafo heterogéneo.

La ventaja cualitativa de MOPPO se observa en los puntos Pareto: 6 en Facebook frente a 4 del mejor baseline. Un usuario con preferencias variables según el contexto no puede obtener esa cobertura con ningún modelo single-objective.

7. Discusión

El sesgo de equidad es el hallazgo más robusto del paper. En todas las configuraciones y todos los métodos, los nodos periféricos cargan desproporcionadamente con el costo. No es un artefacto de MOPPO: es una propiedad estructural del espacio del problema. La extensión natural es incluir un término de equidad en la recompensa:

$$r_{\text{fair}} = r - \lambda_{\text{eq}} \cdot \max(0, \Delta - \Delta^*). \quad (9)$$

El resultado de PPO $\alpha = 1,0$ superando a MOPPO en HV para $k = 4$ merece discusión honesta. Un modelo single-objective converge más rápido porque optimiza un solo gradiente; MOPPO no había convergido completamente con 500 iters en ese régimen. Sin embargo, el HV escalar no distingue entre cobertura amplia del frente y un solo punto dominante: MOPPO produce 3 puntos no dominados mientras PPO $\alpha = 1,0$ produce 2. Más iteraciones deberían cerrar la brecha en HV.

La escalabilidad es una limitación real. Para $n = 500$ el espacio de acciones tiene 125,001 elementos; el action masking reduce el espacio efectivo pero no la dimensión del vector de logits. Una arquitectura jerárquica (manager elige nodo, worker elige arista) reduciría el problema a dos decisiones $O(n)$.

8. Limitaciones y trabajo futuro

Múltiples semillas. Todos los experimentos usan semilla 42. Reportar media y desviación estándar sobre al menos 3 semillas es el estándar de publicación que queda pendiente.




Figura 2: Frentes de Pareto de MOPPO. Color del punto: α (azul/morado = utilidad, amarillo/verde = privacidad). Estrellas rojas: puntos no dominados.

Cuadro 2: Comparacion de HV, puntos Pareto y Δ entre MOPPO y baselines PPO de α fijo. Todos se evaluan con 21 valores de α y 15 episodios. **Negrita:** mejor HV. Subrayado: menor Δ (mas equitativo).

Metodo	Karate $k = 2$			Karate $k = 4$			Facebook $n = 100$		
	HV $\uparrow$	Pts.	$\Delta \downarrow$	HV $\uparrow$	Pts.	$\Delta \downarrow$	HV $\uparrow$	Pts.	$\Delta \downarrow$
PPO $\alpha = 0,0$ (utilidad)	0.9583	1	<u>1.262</u>	0.3871	1	3.016	0.9036	3	<u>3.422</u>
PPO $\alpha = 0,5$ (fijo)	0.9630	1	1.941	0.4233	1	3.482	0.8680	2	3.485
PPO $\alpha = 1,0$ (privacidad)	0.9714	1	2.280	0.4930	2	<u>2.106</u>	0.8530	4	3.804
MOPPO (ours)	0.9727	1	2.110	0.3884	3	2.625	0.8968	6	3.883




Figura 3: Analisis TREX: scatter por cluster, distribucion de α por cluster e indice Δ por cluster. Linea naranja: umbral $\Delta = 1,5$.




Figura 4: Indice Δ por metodo. Linea verde: equidad perfecta. Linea naranja: umbral Rawls $\Delta = 1,5$. PPO $\alpha = 0$ es el unico que lo respeta en $k = 2$.

Baseline greedy. La comparacion con el algoritmo de Liu y Terzi [Liu y Terzi, 2008] completaria el panorama. Es el baseline que los revisores mas probablemente solicitaran.

Equidad como restricción. El indice Δ es descriptivo. La extension directa es penalizarlo en la recompensa con un umbral Δ^* configurable, convirtiendo el problema en un MDP con tres objetivos: privacidad, utilidad y equidad.

Escalabilidad. Una arquitectura jerarquica donde un manager elige el nodo objetivo y un worker elige la arista concreta llevaria la complejidad de $O(n^2)$ a dos decisiones $O(n)$.

9. Conclusion

Presentamos MOPPO, un framework de aprendizaje por refuerzo multi-objetivo que aprende politicas de anonimizacion de grafos para cualquier preferencia de privacidad/utilidad. Las dos contribuciones tecnicas son complementarias: action masking reduce el espacio efectivo 25–45 $\times$, y el curriculum en tres fases estabiliza el entrenamiento eliminando los gradientes contrapuestos iniciales.

Los experimentos alcanzan hipervolumenes de 0.973, 0.388 y 0.897 en karate $k = 2$, $k = 4$ y Facebook respectivamente. MOPPO produce sistematicamente el mayor numero de puntos Pareto (1, 3 y 6), lo que confirma que un solo modelo cubre mas del frente que cualquier politica single-objective.

El hallazgo de equidad es transversal a todos los metodos: los nodos perifericos absorben entre 2,1 $\times$ y 3,9 $\times$ mas impacto relativo que los hubs. Este sesgo es estructural, no es un artefacto del metodo, y la direccion de trabajo mas urgente es incluir un termino explicito de equidad en la funcion de recompensa.




Figura 5: Hipervolumen por metodo en $k = 2$, $k = 4$ y Facebook (paneles izquierdo a centro), y cobertura del frente de Pareto (panel derecho). MOPPO es el unico que sistematicamente produce el mayor numero de puntos Pareto en todos los escenarios.

Referencias

- Abels, A., Roijers, D., Lenaerts, T., Nowe, A., & Steckelmacher, D. (2019). Dynamic weights in multi-objective deep reinforcement learning. *ICML*, pp. 11–20.
- Chester, S., Kapron, B. M., Ramesh, G., Srivastava, G., Thomo, A., & Venkatesh, S. (2013). Why Waldo befriended the dummy? *Soc. Netw. Anal. Min.*, 3(3), 381–399.
- Gao, M., Chen, L., He, X., & Zhou, A. (2022). Reinforcement learning for graph anonymization. *IEEE Trans. Knowl. Data Eng.*, 34(8).
- Hung, C. & Chen, C. (2022). Multi-objective RL for traffic signal control. *Transp. Res. C*, 142, 103799.
- Leskovec, J. & McAuley, J. (2012). Learning to discover social circles in ego networks. *NeurIPS* 25.
- Liu, K. & Terzi, E. (2008). Towards identity anonymization on graphs. *ACM SIGMOD*, pp. 93–106.
- Mauw, S., Ramirez-Cruz, Y., & Trujillo-Rasua, R. (2021). Anonymizing graphs: measuring quality for clustering. *Knowl. Inf. Syst.*, 63, 2365–2397.
- Rajapakse, A., Smith, J., & Lee, K. (2026). TREX: trajectory explanations for MORL. *arXiv:2603.21988*.
- Yang, R., Sun, X., & Narasimhan, K. (2019). A generalized algorithm for MORL and policy adaptation. *NeurIPS* 32.
- You, J., Liu, B., Ying, Z., Pande, V., & Leskovec, J. (2018). Graph convolutional policy network for goal-directed molecular graph generation. *NeurIPS* 31.
- Zachary, W. W. (1977). An information flow model for conflict and fission in small groups. *J. Anthropol. Res.*, 33(4), 452–473.
- Zhou, B. & Pei, J. (2008). Preserving privacy in social networks against neighborhood attacks. *IEEE ICDE*, pp. 506–515.
- Zhou, Z., Li, J., Glass, M., Marple, P., & Chen, S. (2019). Network architecture search for generative adversarial networks. *ICCV*.
- Zitzler, E. & Thiele, L. (1999). Multiobjective evolutionary algorithms: a comparative case study. *IEEE Trans. Evol. Comput.*, 3(4), 257–271.